

Klassifikation von Galaxien im Modul Deep Learning - Meilenstein 1

Alexander Nungesser
HSBI Campus Minden
Artilleriestraße 9, 32427 Minden
alexander.nungesser@hsbi.de

Abstract

Die automatisierte morphologische Klassifikation von Galaxien ist angesichts rasant wachsender astronomischer Datensätze eine hochrelevante Aufgabe der modernen Computer Vision. In dieser Arbeit konzipieren und evaluieren wir tiefe Convolutional Neural Networks (CNNs) "from scratch" zur Kategorisierung des hochauflösenden Galaxy10 DECals Datensatzes in zehn morphologische Klassen. Um den Einfluss architektonischer Designentscheidungen systematisch zu untersuchen, evaluieren wir 14 strukturelle Varianten. Die Ergebnisse zeigen, dass eine durchdachte Netzwerktopologie die reine Parameteranzahl deutlich schlägt: Unsere beste Architektur (V7) erreicht durch den Einsatz von fünf kaskadierten Faltungsblöcken eine Test-Accuracy von 82.36 % bei lediglich 2.49 Millionen Parametern. Im Gegensatz dazu stagniert ein unreguliertes Minimal-Modell mit über 33.6 Millionen Parametern bei 58.40 %. Die Arbeit demonstriert die Effektivität maßgeschneiderter Architekturen, beleuchtet aber auch die Grenzen von von Grund auf trainierten Modellen angesichts starker Klassenungleichgewichte, was künftige Ansätze mittels Transfer Learning motiviert.

1. Einleitung

Die automatisierte Klassifikation von Objekten in digitalen Bildern ist eine der zentralen Aufgabenstellungen im Bereich der Computer Vision. Insbesondere tiefe künstliche neuronale Netze, spezifisch Convolutional Neural Networks (CNNs), haben sich hierfür als äußerst effektiv erwiesen und bilden das Rückgrat moderner Bilderkennungssysteme. Während in der Praxis häufig etablierte Standardarchitekturen mittels Transfer Learning genutzt werden, erfordert ein tiefes Verständnis der zugrundeliegenden Merkmalsextraktion den systematischen Entwurf und die Analyse eigener, maßgeschneiderter Netzarchitekturen.

Diese Arbeit befasst sich im Rahmen der Aufgabenstellung "Architecture Design" mit der Entwicklung und Evaluation einer eigenen CNN-Architektur zur Objektklassifikation. Als Datengrundlage dient der im nachfolgenden

Kapitel detailliert beschriebene *Galaxy10 DECals-Datensatz*. Astronomische Datensätze dieser Art stellen aufgrund ihrer komplexen morphologischen Merkmale und inhärenten Klassenungleichgewichte besondere Anforderungen an die vorbereitende Datenüberprüfung und die Robustheit des Modells.

Das Hauptziel dieser Arbeit ist die Konstruktion eines tiefen neuronalen Netzes "from scratch", dessen Basisarchitektur aus mindestens fünf Faltungsschichten (Convolutional Layers) und mindestens zwei vollvernetzten Schichten (Fully Connected Layers) besteht. Um die Auswirkungen architektonischer Designentscheidungen auf die Modellleistung systematisch zu untersuchen, evaluieren wir mindestens zehn unterschiedliche strukturelle Varianten dieses Basismodells. Entsprechend der methodischen Vorgaben liegt der Fokus hierbei explizit auf echten architektonischen Modifikationen (z. B. Anpassung der Filtergrößen, Hinzufügen von Layern) und nicht auf der bloßen Variation von Hyperparametern wie der Epochenanzahl, der Batch-Größe oder dem gewählten Optimierer.

Zusammenfassend liefert dieses Paper die folgenden Beiträge:

- Die Konzeption einer eigenen, problembezogenen CNN-Architektur zur Galaxienklassifikation.
- Eine systematische Gegenüberstellung und Evaluation von über zehn strukturellen Netzvarianten zur Identifikation des optimalen Architekturentwurfs.
- Eine fundierte Diskussion der Ergebnisse unter Berücksichtigung der Datenqualität und möglicher Limitationen.

Im weiteren Verlauf dieser Arbeit wird der verwendete Datensatz vorgestellt. Außerdem werden die methodische Konzeption der Basisarchitektur sowie der untersuchten Varianten beschrieben. Die experimentellen Ergebnisse werden präsentiert und diskutiert, bevor die Arbeit mit einer Zusammenfassung abgeschlossen wird.

2. Der Galaxy10 DECals Datensatz

Für die Evaluierung unserer Methodik verwenden wir den **Galaxy10 DECals** Datensatz [2], der von der astroNN-Forschungsgruppe kuratiert und standardisiert wurde. Es

Table 1. Verteilung der zehn morphologischen Klassen im Galaxy10 DECaLS Datensatz [2, 4].

Klasse	Morphologische Beschreibung	Anzahl
0	Gestörte Galaxien (Disturbed)	1081
1	Verschmelzende Galaxien (Merging)	1853
2	Runde, glatte Galaxien	2645
3	Mittelrunde, glatte Galaxien	2027
4	Zigarrenförmige, glatte Galaxien	334
5	Balkenspiralgalaxien	2043
6	Spiralgalaxien ohne Balken (eng)	1829
7	Spiralgalaxien ohne Balken (weit)	2628
8	“Edge-on” Galaxien ohne Bulge	1423
9	“Edge-on” Galaxien mit Bulge	1873

handelt sich hierbei um eine hochauflösende Weiterentwicklung des ursprünglichen Galaxy10 SDSS-Datensatzes. Die Bilddaten basieren auf Aufnahmen der *DESI (Dark Energy Spectroscopic Instrument) Legacy Imaging Surveys* (DECaLS), während die morphologischen Ground-Truth-Labels aus Crowdsourcing-Abstimmungen des *Galaxy Zoo DR2* Projekts abgeleitet wurden [1].

2.1. Struktur und Bildeigenschaften

Der Datensatz umfasst insgesamt 17736 Bilder. Jedes Bild liegt in einer Auflösung von 256×256 Pixeln mit drei spektralen Kanälen (g -, r - und z -Band) vor [4]. Im Rahmen des Preprocessing-Schrittes werden die Pixelintensitäten standardisiert in den Fließkommabereich $[0, 1]$ skaliert, um eine optimale Konvergenz für das nachfolgende Deep-Learning-Modell zu gewährleisten.

2.2. Klassifizierung und Datenverteilung

Die Galaxien sind in zehn morphologische Klassen unterteilt, die verschiedene evolutionäre und strukturelle Merkmale abbilden (z. B. Spiralen, Ellipsen, Kollisionen). Wie in Tab. 1 dargestellt, weist der Datensatz eine signifikante Klassenimbalance auf.

Während Klassen wie die “runden, glatten Galaxien” (Klasse 2) oder “Spiralgalaxien ohne Balken” (Klasse 7) stark repräsentiert sind, ist die Klasse 4 (“zigarrenförmig”) mit nur 334 Samples stark unterrepräsentiert. Dies erfordert beim Training in der Regel ausgleichende Maßnahmen wie Data-Augmentation (z. B. Rotationen, Spiegelungen) oder klassengewichtete Verlustfunktionen, um einen Modell-Bias zu verhindern [1].

3. Eigene Methoden

In diesem Abschnitt beschreiben wir die vorgeschlagene Basisarchitektur zur Klassifikation der Galaxienmorphologie sowie die systematischen architektonischen Variationen, die zur Evaluation des optimalen Netzwerkdesigns

durchgeführt wurden. Der vollständige Quellcode der implementierten Basisarchitektur, die Konfigurationen aller zehn evaluierten Strukturvarianten sowie die Skripte zur Datenvorverarbeitung sind zur Gewährleistung der Reproduzierbarkeit im öffentlich zugänglichen GitHub-Repository hinterlegt [3].

3.1. Statische Trainingskonfiguration und Datenvorverarbeitung

Um eine objektive Vergleichbarkeit der im weiteren Verlauf vorgestellten Architekturvarianten zu gewährleisten, wurde für alle Experimente eine identische, statische Trainingsumgebung definiert. Die Modifikation dieser grundlegenden Hyperparameter und Trainingsroutinen ist explizit nicht Teil der architektonischen Evaluation.

Optimierung und Hyperparameter: Alle Modelle werden für maximal 100 Epochen mit einer Batch-Größe von 16 trainiert. Als Optimierungsalgorithmus kommt *Adam* mit einer initialen Lernrate von 10^{-4} zum Einsatz. Das Trainingsziel ist die Minimierung der *Categorical Cross-Entropy Loss*, während die Klassifikationsgenauigkeit (Accuracy) als primäre Evaluationsmetrik erfasst wird.

Data Augmentation: Um Überanpassung (Overfitting) entgegenzuwirken und die Generalisierungsfähigkeit der Modelle zu erhöhen – insbesondere angesichts der komplexen Morphologie der Galaxien –, wird eine Datenaugmentierung direkt als Vorverarbeitungsschicht in die Modellpipeline integriert. Diese umfasst geometrische Transformationen, die zur Laufzeit auf die Trainingsdaten angewendet werden:

- Zufällige Translationen um bis zu $\pm 10\%$ in Höhe und Breite.
- Zufällige Spiegelungen entlang der horizontalen und vertikalen Achse.
- Zufällige Rotationen mit einem Faktor von 0.2.
- Zufällige Skalierungen (Zoom) um bis zu $\pm 10\%$ in Höhe und Breite.

Trainingssteuerung (Callbacks): Zur dynamischen und effizienten Überwachung des Trainingsprozesses wurde eine Reihe von Callbacks implementiert. Ein *Early Stopping*-Mechanismus bricht das Training vorzeitig ab, falls sich die Validierungs-Loss nach einer definierten Anzahl von Epochen (Patience) nicht weiter verbessert; dabei werden automatisch die Gewichte der besten Epoche wiederhergestellt (*restore best weights*). Um bei stagnierender Validierungs-Loss eine feinere Konvergenz zu erzwingen, reduziert ein *ReduceLROnPlateau*-Callback die Lernrate um den Faktor 0.5 (bis zu einem Minimum von 10^{-6}). Zusätzlich wird über den *ModelCheckpoint* stets das bestperformende Modell (gemessen an der Validierungs-Accuracy) als ‘.keras’-Datei gespeichert, während der gesamte Trainingsverlauf systematisch via *TensorBoard* protokolliert wird.

3.2. Basisarchitektur (Base-CNN)

Um eine fundierte Baseline für unsere Experimente zu schaffen, haben wir ein Convolutional Neural Network (CNN) "from scratch" entworfen. Die Basisarchitektur besteht aus einer Kaskade von fünf Faltungsschichten (Convolutional Layers) zur Merkmalsextraktion, gefolgt von zwei vollvernetzten Schichten (Fully Connected Layers) zur finalen Klassifikation.

Die Faltungsschichten verwenden sequenziell aufsteigende Filteranzahlen (32, 64, 128, 256, 256), um zunehmend komplexe abstrakte Repräsentationen zu erlernen. In allen Faltungsschichten kommen Filter der Größe 3×3 mit *Same-Padding* sowie die nicht-lineare Aktivierungsfunktion ReLU (Rectified Linear Unit) zum Einsatz. Zur räumlichen Dimensionsreduktion und zur Erhöhung der Translationsinvarianz wird nach jedem Convolutional Layer ein Max-Pooling-Layer mit einer Fenstergröße von 2×2 angewendet.

Nach der Merkmalsextraktion werden die Feature-Maps durch eine Flatten-Operation vektorisiert und an einen Dense-Layer mit 512 Neuronen (ReLU-Aktivierung) übergeben. Der finale Output-Layer besteht aus 10 Neuronen, die mittels Softmax-Aktivierung eine Wahrscheinlichkeitsverteilung über die zehn Galaxienklassen des Datensatzes ausgeben.

3.3. Systematische Architekturvarianten

Um den Einfluss spezifischer Designentscheidungen auf die Modellkapazität, den Receptive Field Size und die Generalisierungsfähigkeit zu untersuchen, haben wir zehn strukturelle Varianten der Basisarchitektur evaluiert. Reine Hyperparameter wie Lernrate oder Epochenanzahl blieben dabei konstant, um eine isolierte Betrachtung der Architektur zu gewährleisten. Die Modifikationen umfassen Änderungen an der Netzwerkbreite und -tiefe sowie die Einführung von Regularisierungstechniken. Tab. 2 fasst die evaluierten Netzwerktopologien zusammen.

Während Varianten wie *Var_Filter_Double* und *Var_Extra_Conv* die Modellkapazität erhöhen, zielen *Var_Dropout* und *Var_BatchNorm* darauf ab, Overfitting – insbesondere bei den unterrepräsentierten Klassen des Datensatzes – entgegenzuwirken und die Trainingsstabilität zu verbessern.

3.4. Trainingsziel (Training Objective)

Das Training aller Modelle erfolgt durch die Minimierung der *Categorical Cross-Entropy Loss*. Für ein Datenset mit N Beispielen und C Klassen wird das Netzwerk darauf optimiert, die Gewichte W so anzupassen, dass die Abweichung zwischen den vorhergesagten Wahrscheinlichkeiten und den Ground-Truth-Labels minimiert wird.

Table 2. Übersicht der zehn evaluierten Architekturvarianten im Vergleich zur Basisarchitektur.

Modellname	Architektonische Modifikation
Base-CNN	Baseline (5 Conv, 2 Dense, ohne Reg.)
Var_Filter_Half	Reduktion aller Conv-Filter um 50 % (16, 32, 64, 128, 128)
Var_Filter_Double	Verdopplung aller Conv-Filter (64, 128, 256, 512, 512)
Var_Kernel_5x5	Erhöhung der Kernel-Größe in Conv 1 und 2 auf 5×5
Var_No_Pool_4	Entfernung des 4. Max-Pooling-Layers
Var_Extra_Conv	Hinzufügen eines 6. Conv-Layers (512 Filter, 3×3)
Var_Dense_Small	Reduktion des ersten Dense-Layers auf 128 Neuronen
Var_Dense_Large	Erweiterung des ersten Dense-Layers auf 1024 Neuronen
Var_Dropout_0.3	Einfügen von Dropout ($p = 0.3$) nach jedem Dense-Layer
Var_Dropout_0.5	Einfügen von Dropout ($p = 0.5$) nach jedem Dense-Layer
Var_BatchNorm	Einfügen von Batch Normalization nach jedem Conv-Layer

4. Ergebnisse

In diesem Abschnitt präsentieren wir die quantitativen und qualitativen Ergebnisse unserer systematischen Architekturevaluation auf dem Galaxy10 DECals Testdatensatz. Die Leistungsfähigkeit der einzelnen Modellvarianten wurde primär anhand der globalen Klassifikationsgenauigkeit (Test Accuracy) gemessen, wobei auch die Parameteranzahl als Indikator für die Modelleffizienz berücksichtigt wurde.

4.1. Quantitative Modellauswertung

Wie in Tab. 3 dargestellt, übertreffen unsere optimierten Custom-Architekturen die unregulierte Baseline (Minimal-Modell) signifikant. Das *Minimal-Modell* erreichte trotz einer massiven Überparametrisierung von rund 33.6 Millionen Parametern lediglich eine Accuracy von 58.40 %. Dies deutet auf ein starkes Overfitting sowie auf ineffiziente Merkmalsextraktion hin, was durch die stark divergierenden Trainings- und Validierungsverluste in den Lernkurven (siehe Abb. 17 im Anhang) bestätigt wird. Im Gegensatz dazu zeigen die Trainingsverläufe der optimierten Modelle (z.,B. Abb. 6) eine deutlich stabilere Konvergenz.

Durch den strategischen Einsatz kaskadierter Faltungsblöcke konnte dieses Verhalten drastisch verbessert werden. Die Variante **V7 (v7 five conv blocks)** erwies sich mit einer **Test-Accuracy von 82.36 %** als leistungsstärkstes Modell der Versuchsreihe. Eine detaillierte Visualisierung der Schichtarchitektur dieses Modells findet sich in Abbildung 5 im Anhang. Dicht darauf folgen das *BEST-CNN*

(82.33 %) und Modell V9 (82.27 %), die ähnliche strukturelle Topologien aufweisen. Es ist bemerkenswert, dass V7 diese Spitzenleistung mit nur 2.49 Millionen Parametern erreicht – eine Parameterreduktion um mehr als 92 % gegenüber dem Minimal-Modell bei gleichzeitiger Genauigkeitssteigerung um fast 24 Prozentpunkte.

Table 3. Testgenauigkeit (Accuracy) und Parameteranzahl der Top-5 Custom-Modelle im Vergleich zur Baseline.

Rang	Variante	Parameter	Test-Acc.
1	V7 (five.conv.blocks)	2 492 202	82.36 %
2	BEST_CNN	2 492 202	82.33 %
3	V9 (with_512.dense)	2 754 858	82.27 %
4	V12 (with_dense.bn)	2 493 226	82.19 %
5	V5 (deeper_dense)	684 970	80.67 %
12	Minimal-Modell (Base)	33 648 394	58.40 %

4.2. Klassenspezifische Analyse und Modellkomplexität

Der Zusammenhang zwischen Modellkomplexität und Genauigkeit (vgl. Abb. 1 im Anhang) verdeutlicht, dass ab einer Kapazität von etwa 2.5 Millionen Parametern ein Sättigungseffekt eintritt. Eine bloße Erhöhung der Dense-Neuronen (wie in V9 mit 2.75 Millionen Parametern) führt zu keiner signifikanten Leistungssteigerung mehr.

Die Analyse der Wahrheitsmatrizen (Confusion Matrices) der besten Netze (V7, BEST_CNN, V9) (siehe Abb. 2 bis 4 im Anhang) offenbart zudem klassenspezifische Stärken und Schwächen. Während stark repräsentierte morphologische Klassen (z. B. *Runde, glatte Galaxien* oder *Spiralgalaxien ohne Balken*) mit einer Genauigkeit von oft über 90 % erkannt werden, zeigt das Modell signifikante Unsicherheiten bei seltenen Phänomenen wie den zigarrenförmigen Galaxien (Klasse 4). Zwischen den Klassen 2 und 3 (*Runde* vs. *Mittelrunde Galaxien*) treten die häufigsten Verwechslungen (Misclassifications) auf, was auf die stark fließenden visuellen Übergänge dieser morphologischen Kategorien zurückzuführen ist.

5. Diskussion

Die systematische Variation der Netzwerkarchitektur hat eindrucksvoll gezeigt, dass nicht die reine Modellgröße (Anzahl der Parameter), sondern die durchdachte Komposition von Faltungs- und Pooling-Schichten entscheidend für die Leistungsfähigkeit eines CNNs ist. Das Sieger-Modell V7 belegt, dass fünf tiefe Convolutional-Blöcke ausreichen, um die komplexen räumlichen Hierarchien astronomischer Bilder effektiv zu extrahieren.

Dennoch stoßen von Grund auf neu trainierte Custom-Architekturen an systematische Limitierungen. Das Hauptproblem – und zugleich die größte Herausforderung dieser

Studie – bleibt die fundamentale Klassenimbalance des Galaxy10 DECals Datensatzes. Trotz intensiver Data Augmentation tendiert das Netzwerk dazu, sich auf dominante Klassen zu fokussieren und seltene Galaxienformen zu vernachlässigen. Eine Anpassung der Loss-Funktion (z. B. durch *Class Weights* oder *Focal Loss*) könnte in zukünftigen Experimenten Abhilfe schaffen.

Darüber hinaus limitieren die verfügbare Datenmenge und die von Scratch initialisierten Gewichte die maximale Modellkapazität. Während unser Modell eine Accuracy von ca. 82 % erreicht, haben State-of-the-Art-Ansätze in der Literatur gezeigt, dass tiefe, vortrainierte Architekturen deutlich robuster extrahieren können. Dies motiviert den nächsten logischen Forschungsschritt: Im Rahmen zukünftiger Arbeiten (vgl. Station 2) wird evaluiert, inwiefern etablierte Architektur-Giganten wie ResNet oder VGG in Verbindung mit Transfer Learning die hier identifizierten Grenzen der Klassifikationsgenauigkeit durchbrechen können.

6. Zusammenfassung

In der vorliegenden Arbeit wurde der systematische Entwurf und die Evaluierung eigener Convolutional Neural Networks zur Klassifizierung der Galaxienmorphologie auf dem Galaxy10 DECals Datensatz durchgeführt. Durch die systematische Variation von Architekturmerkmalen wie der Netzwerktiefe, der Filteranzahl und dem Einsatz von Regularisierungsmethoden konnten tiefgreifende Erkenntnisse über das Feature-Learning in komplexen astronomischen Bilddaten gewonnen werden.

Es konnte empirisch belegt werden, dass ein effizientes Architecture Design entscheidender ist als rohe Modellkapazität. Während stark überparametrisierte, aber flache Netzwerke schnell überanpassten und unzureichend generalisierten, erzielte unsere beste Architekturvariante V7 (*v7_five_conv_blocks*) durch fünf sequenzielle Faltungsblöcke und strategisches Pooling eine signifikante Leistungssteigerung auf 82.36 % Testgenauigkeit – und das bei einer drastischen Reduktion der Parameter.

Gleichzeitig hat die Evaluation die Limitierungen dieses Ansatzes aufgezeigt. Insbesondere die inhärente Klassenimbalance des Datensatzes führt bei Modellen, die vollständig "from scratch" trainiert werden, zu Schwächen bei der Erkennung seltener Galaxientypen (wie z. B. zigarrenförmigen Galaxien).

References

- [1] Tuan Le et al. Enhanced comparative analysis of pretrained and custom deep convolutional neural networks for galaxy morphology classification. *MDPI Algorithms*, 17(3):100–115, 2024. 2
- [2] Henry W. Leung and Jo Bovy. astronnn: Deep learning for astronomers with tensorflow. <https://astronnn>.

readthedocs.io/en/latest/galaxy10.html, 2019. Accessed: 2026-05-17. [1](#), [2](#)

- [3] Alexander Nungesser. Deep learning project repository. <https://github.com/AlexanderNungesser/deep-learning>, 2026. Accessed: 2026-05-18. [2](#)
- [4] Y. You. Evaluation of galaxy morphology classification with machine learning and deep learning. In *Proceedings of the International Conference on Information Technology and Applications*, pages 245–252. Atlantis Press, 2024. [2](#)

A. Zusätzliche Abbildungen und Plots




Figure 1. Vergleich der Modellkomplexität (Parameteranzahl) und der Test-Genauigkeit (Accuracy) über alle evaluierten Architekturvarianten.




Figure 2. Wahrheitsmatrix (Confusion Matrix) des leistungsstärksten Modells V7 (v7_five_conv_blocks) auf dem Galaxy10 Testdatensatz.




Figure 3. Wahrheitsmatrix (Confusion Matrix) des zweitbesten Modells BEST_CNN (9_conv_layer_cnn) auf dem Galaxy10 Testdatensatz.




Figure 4. Wahrheitsmatrix (Confusion Matrix) des drittbesten Modells V9 (v9_with_512_dense) auf dem Galaxy10 Testdatensatz.




Figure 6. Trainingsverlauf (Accuracy und Loss) des bestplatzierten Modells V7 (*v7_five_conv_blocks*).




Figure 7. Trainingsverlauf (Accuracy und Loss) des zweitplatzierten Modells *BEST_CNN* (*9_conv_layer_cnn*).




Figure 8. Trainingsverlauf (Accuracy und Loss) des Modells V9 (*v9_with_512_dense*).




Figure 9. Trainingsverlauf (Accuracy und Loss) des Modells V12 (*v12_with_dense_bn*).




Figure 10. Trainingsverlauf (Accuracy und Loss) des Modells V5 (*v5_deeper_dense*).




Figure 11. Trainingsverlauf (Accuracy und Loss) des Modells V6 (*v6_with_dropout_03*).




Figure 12. Trainingsverlauf (Accuracy und Loss) des Modells V8 (*v8_five_conv_dropout*).




Figure 13. Trainingsverlauf (Accuracy und Loss) des Modells V11 (*v11_best_cnn_deeper_dense*).




Figure 14. Trainingsverlauf (Accuracy und Loss) des Modells V4 (*v4_deeper_filters*).




Figure 15. Trainingsverlauf (Accuracy und Loss) des Modells V10 (*v10_best_cnn_lite*).




Figure 16. Trainingsverlauf (Accuracy und Loss) des Modells V3 (*v3_double_conv_bn*).




Figure 17. Trainingsverlauf (Accuracy und Loss) des *Minimal-Modells* (*minimal_cnn*).




Figure 18. Trainingsverlauf (Accuracy und Loss) des Modells V1 (*v1_minimal_with_bn*).




Figure 19. Trainingsverlauf (Accuracy und Loss) des Modells V2 (*v2_minimal_bn_gap*).