

Klassifikation von Galaxien im Modul Deep Learning - Meilenstein 1

Alexander Nungesser
HSBI Campus Minden
Artilleriestraße 9, 32427 Minden
alexander.nungesser@hsbi.de

Abstract

Die vorliegende Arbeit untersucht den Einsatz von Knowledge Distillation zur ressourceneffizienten Klassifikation von Galaxienmorphologien auf Basis des hochauflösenden Galaxy10 DECals Datensatzes. Während in vorangegangenen Projektphasen Klassifikationsergebnisse (89.12 %) durch Transfer Learning mit großen Modellen (über 15 Millionen Parameter) erzielt wurden, sind derart rechenintensive Architekturen für die Verarbeitung astronomischer Big Data oftmals ungeeignet. Um diesen Konflikt zwischen Genauigkeit und Effizienz zu lösen, implementieren wir eine Offline-Distillationspipeline, die das tiefgreifende Wissen (Soft Labels) des komplexen Zoobot-Teachers auf stark komprimierte Student-Netzwerke überträgt. Unsere systematische Evaluierung von sieben Architekturvarianten belegt, dass Knowledge Distillation die Generalisierungsfähigkeit kleiner Netzwerke erheblich erhöht. Das leistungsstärkste Student-Modell (S6_XL) erreicht eine Testgenauigkeit von 86.81 % bei lediglich 1.84 Millionen Parametern. Damit übertrifft es konventionell trainierte Basismodelle gleicher oder größerer Kapazität signifikant und bietet einen State-of-the-Art-Kompromiss, der die Lücke zu rechenintensiven Transfer-Learning-Modellen schließt, ohne deren Inferenzkosten zu erben.

1. Einleitung

Die morphologische Klassifikation von Galaxien bildet eine essenzielle Grundlage für das Verständnis der Entstehung und Evolution unseres Universums. Mit dem kontinuierlichen Wachstum astronomischer Bilddatenbanken, wie dem hier verwendeten Galaxy10 DECals Datensatz, wird der Einsatz robuster, automatisierter Deep-Learning-Methoden unerlässlich. Vorangegangene Arbeiten in diesem Projekt haben gezeigt, dass die Leistungsfähigkeit von Grund auf trainierter Convolutional Neural Networks (CNNs) stark durch die verfügbare Datenmenge und signifikante Klassenimbilanzen limitiert wird [4]. So erzielte unser bestes proprietäres Basismodell (Variante V7) zwar eine solide Testge-

nauigkeit von 82.36 %, stieß jedoch mit knapp 2.49 Millionen Parametern an seine Generalisierungsgrenzen [4].

Eine substantielle Leistungssteigerung auf 89.12 % konnte erst in einer zweiten Projektphase durch den Paradigmenwechsel hin zum Transfer Learning erzielt werden [5]. Dabei erwiesen sich generische Architekturen wie ResNet oder Inception V3 als ineffektiv für diese spezialisierte Domäne; lediglich das domänenspezifische, auf astronomischen Daten vortrainierte Zoobot-Modell (basierend auf der ConvNeXt-Nano-Architektur) lieferte nach einem gezielten Finetuning exzellente Ergebnisse [5]. Dieser Genauigkeitsgewinn fordert jedoch einen hohen Preis: Mit über 15 Millionen Parametern ist das Zoobot-Modell deutlich überparametrisiert [5]. Für den Einsatz in ressourcenbeschränkten Umgebungen oder zur Echtzeitauswertung enormer Himmelsdurchmusterungen ist ein derart rechenintensives Modell, bedingt durch hohe Inferenzzeiten und enormen Speicherbedarf, in der Praxis oft ungeeignet.

Um diesen grundlegenden Konflikt zwischen Klassifikationsgenauigkeit und Modelleffizienz zu lösen, evaluieren wir in dieser Arbeit den Ansatz der Knowledge Distillation (Wissenstransfer). Hierbei fungiert das präzise, aber komplexe Zoobot-Modell als "Teacher". Dessen tiefes Verständnis der Datenstruktur, repräsentiert durch die Wahrscheinlichkeitsverteilungen der Ausgabe (Soft Labels), wird genutzt, um ein deutlich kompakteres "Student"-Modell zu trainieren. Gemäß der methodischen Zielsetzung wird das Student-Modell so entworfen, dass seine Parameteranzahl strikt unterhalb der Kapazität der in Station 1 evaluierten Modelle (weniger als 2.49 Millionen Parameter) liegt, während es gleichzeitig die Klassifikationsgüte des Teachers bestmöglich approximieren soll.

Zusammenfassend liefert diese Arbeit folgende Hauptbeiträge:

- Die Implementierung einer *Offline Knowledge Distillation*-Pipeline unter Verwendung des domänenspezifisch finetunten Zoobot-Modells als Teacher.
- Die Konstruktion und das Training extrem ressourceneffizienter Student-Netzwerke, deren Modellkapazität be-

wusst klein gehalten wird.

- Eine vergleichende quantitative Evaluierung, die aufzeigt, inwiefern der durch Knowledge Distillation erreichte Genauigkeitsgewinn im Vergleich zum direkten Training (*from scratch*) der Student-Modelle auf den One-Hot-Labels (*Hard Labels*) gesteigert werden kann.

Im weiteren Verlauf dieser Arbeit wird in Abschnitt 2 die theoretische Funktionsweise der Knowledge Distillation erläutert. Abschnitt 3 beschreibt die methodische Umsetzung und die gewählten Teacher-Student-Architekturen. Die experimentellen Ergebnisse werden in Abschnitt 4 präsentiert und in Abschnitt 5 abschließend diskutiert.

2. Eigene Methoden

Um den Konflikt zwischen Modellkomplexität und Inferenzgeschwindigkeit zu lösen, implementieren wir eine *Offline Knowledge Distillation* (KD) Pipeline. Dieser Ansatz zielt darauf ab, das tiefgreifende Feature-Wissen eines hochkomplexen Modells (Teacher) auf ressourceneffiziente Architekturen (Student) zu übertragen.

2.1. Teacher-Modell und Logit-Extraktion

Als Teacher-Modell fungiert das in Station 2 [5] evaluierte und auf den Galaxy10 DECals Datensatz feingetunte *Zoobot*-Modell. Basierend auf einer ConvNeXt-Nano-Architektur erreicht dieses Modell mit über 15 Millionen Parametern eine herausragende Testgenauigkeit von ca. 89.12 %. Um den rechnerischen Aufwand des simultanen Trainings zu eliminieren, wird der Teacher eingefroren. In einem vorgelegerten Offline-Prozess werden die unskalierten Netzwerkausgaben (Logits) des Teachers für alle Trainings- und Validierungsdaten extrahiert und als Referenzwerte (.npv-Dateien) persistiert [3].

2.2. Architektur der Student-Modelle

Entsprechend der methodischen Restriktionen müssen die Student-Modelle eine geringere Komplexität aufweisen als die in Station 1 entwickelte Baseline (V7 mit 2.49 Millionen Parametern) [4]. Wir definieren eine Progression von sieben Convolutional Neural Networks (S1_Nano bis S7_Max). Die Modelle iterieren von extrem kompakten Netzwerken (S1_Nano, ca. 64 000 Parameter) bis hin zur maximal erlaubten Kapazitätsgrenze (S7_Max, ca. 2.03 Millionen Parameter). Alle Modelle enden bewusst in einem linearen Dense-Layer ohne Softmax-Aktivierung, um die rohen Logits für die nachfolgende Temperaturskalierung der Loss-Funktion bereitzustellen.

2.3. Loss-Funktion und Distillationsparameter

Das Training der Student-Modelle basiert auf der Formulierung aus der Vorlesung. Die Gesamtkostenfunktion $\mathcal{L}_{total}$ setzt sich aus einer gewichteten Kombination der

Standard-Kreuzentropie (Hard Labels) und der Kullback-Leibler-Divergenz (Soft Labels) zusammen:

$$\mathcal{L}_{total} = \alpha \cdot \mathcal{L}_{CE}(y, \sigma(z_s)) + (1 - \alpha) \cdot \mathcal{D}_{KL}\left(\sigma\left(\frac{z_t}{T}\right), \sigma\left(\frac{z_s}{T}\right)\right) \quad (1)$$

Hierbei bezeichnen z_t und z_s die Logits des Teachers respektive des Students. Die Softmax-Funktion σ wird durch den Temperaturparameter T skaliert, um die sekundären Wahrscheinlichkeiten der Teacher-Klassifikation (die sogenannte "Dark Knowledge") für den Student hervorzuheben. In unseren Experimenten wurden die Hyperparameter empirisch auf $T = 5.0$ und eine Gewichtung von $\alpha = 0.1$ festgelegt, was den Einfluss der Soft Labels stark priorisiert.

3. Ergebnisse

Die quantitative Auswertung der sieben Student-Modelle zeigt, dass die Knowledge Distillation die Leistungsfähigkeit kompakter Modelle enorm steigert. Wie in den detaillierten Trainings- und Validierungsverläufen im Anhang (Abb. 2) ersichtlich, konvergieren alle Architekturvarianten stabil.

3.1. Modellperformance und Kapazitätseffizienz

Um den methodischen Vorgaben gerecht zu werden, iterieren die Architekturen der Student-Modelle strikt unterhalb der Parametergrenze des besten Modells aus Station 1 (siehe Tab. 1).

Table 1. Parameterprogression der evaluierten Student-Modelle im Vergleich zur Baseline (Station 1) und dem Teacher (Station 2). Alle Distillations-Modelle unterbieten die festgelegte Kapazitätsgrenze von knapp 2.5 Millionen Parametern.

Modell / Architektur	Parameteranzahl
Teacher: Zoobot (Station 2)	~15 110 000
Baseline: V7 (Station 1)	2 492 202
Student: S7_Max	2 030 000
Student: S6_XL (Bestes Modell)	1 840 000
Student: S5_Large	1 240 000
Student: S4_Base	1 100 000
Student: S3_Medium	619 000
Student: S2_Small	251 000
Student: S1_Nano	64 000

Die Evaluation identifizierte das Modell **S6_XL** (1.84 Millionen Parameter) als das leistungsstärkste Student-Netzwerk mit einer globalen Testgenauigkeit von 86.81 %. Interessanterweise führte eine weitere Erhöhung der Modellkapazität (S7_Max mit 2.03 Millionen Parametern) zu einem leichten Genauigkeitsabfall auf 86.41 %, was auf ein einsetzendes Overfitting oder eine Sättigung des Informationstransfers hindeutet.

Der Vergleich der Trainingsansätze belegt den deutlichen Mehrwert der Distillation: S6_XL übertrifft Modelle äquivalenter Größe, die klassisch *from scratch* auf Hard Labels trainiert wurden, signifikant. Eine genaue Gegenüberstellung des relativen Genauigkeitsgewinns über alle evaluierten Modellgrößen hinweg findet sich in Abbildung 3 (siehe Anhang).

3.2. Klassenspezifische Evaluation




Figure 1. Wahrheitsmatrix (Confusion Matrix) des besten Student-Modells (S6_XL) auf dem Testdatensatz. Die Hauptdiagonale belegt eine hohe Gesamtgenauigkeit, offenbart jedoch spezifische Schwächen bei gestörten Morphologien (Klasse 1) und fließenden Übergängen (Klassen 7 und 8).

Die Analyse der Wahrheitsmatrix des besten Student-Modells (S6_XL, siehe Abb. 1) verdeutlicht einerseits die klassenspezifische Robustheit des Modells: Eindeutige, stark repräsentierte morphologische Ausprägungen werden mit hoher Konfidenz klassifiziert. Andererseits lassen sich aus der Matrix spezifische Fehlerschwerpunkte ablesen. Neben den zu erwartenden Verwechslungsraten bei unterrepräsentierten Klassen wie den zigarrenförmigen Galaxien (Klasse 5), zeigt das Modell signifikante Schwierigkeiten bei der korrekten Zuordnung der *Disturbed Galaxies* (Klasse 1) sowie bei der präzisen Unterscheidung der *Unbarred Tight Spiral Galaxies* (Klasse 7) von den *Unbarred Loose Spiral Galaxies* (Klasse 8).

Diese fehlerhaften Erkennungen lassen sich durch die visuelle Komplexität der Datenstruktur erklären: Gestörte Galaxien (Abb. 5a) weisen per Definition irreguläre, oft asymmetrische Strukturen auf, wodurch sie vom Netzwerk häufig fehlerhaft als verschmelzende Galaxien (*Merging Galaxies*, Klasse 2) interpretiert werden. Bei den balkenlosen Spiralgalaxien (Klassen 7 und 8) hingegen sind die

morphologischen Übergänge extrem fließend. Die subtilen visuellen Nuancen in der Wicklungsdichte der Spiralarme ("tight" vs. "loose") verschwimmen durch die Auflösungsgrenzen der Bilder stark. (siehe Abb. 5b, 5c)

Dieser Umstand belegt eine wesentliche Erkenntnis: Die feinen optischen Trennlinien dieser Klassen stellen selbst für das hochkomplexe Teacher-Modell eine Herausforderung dar. Folglich kann die Knowledge Distillation die inhärenten Unschärfen der visuellen Klassengrenzen sowie die Klassen-imbalance des Galaxy10 Datensatzes [2, 6] zwar im Soft-Label-Transfer abbilden, sie jedoch nicht gänzlich auflösen.

4. Diskussion

Die vergleichende Analyse über alle drei Projektphasen hinweg (siehe Abb. 4 im Anhang) beweist den Erfolg der Knowledge Distillation. In Station 1 [4] erreichte unser bestes proprietäres Modell (V7) eine Genauigkeit von 82.36 % bei knapp 2.5 Millionen Parametern. Durch den Einsatz des feingetunten Zoobot-Teachers (89.12 %) aus Station 2 [5] konnte das Student-Modell S6_XL diese Baseline um fast 4.5 Prozentpunkte auf 86.81 % übertreffen – und das bei einer Parameterreduktion von rund 26 % gegenüber Station 1.

Das Student-Modell approximiert das Wissen des großen 15-Millionen-Parameter-Teachers mit lediglich 12 % dessen Kapazität. Die überlegene Repräsentation der "Dark Knowledge" – also die impliziten Ähnlichkeiten zwischen morphologischen Ausprägungen, wie die weichen Übergänge zwischen Ellipsen und Runden Galaxien, die vom Teacher erlernt wurden – fungiert als effektiver Regularisator [1].

Limitierend bleibt jedoch anzumerken, dass die Qualität des Student-Modells intrinsisch an die Güte des Teachers gebunden ist. Fehler oder Biases, die der Teacher aufgrund der Datensatz-Imbalance aufweist, werden unweigerlich an den Student weitergegeben. Zukünftige experimentelle Ansätze könnten die Hyperparameter der Distillation (T , α) dynamisch an die Repräsentationsdichte der jeweiligen Klasse anpassen, um die Minderheitenklassen im Distillationsprozess stärker zu gewichten.

5. Zusammenfassung

Diese Arbeit demonstriert erfolgreich die Anwendung von Knowledge Distillation zur effizienten Klassifikation der Galaxienmorphologie. Es konnte gezeigt werden, dass der Transfer von Soft-Label-Wahrscheinlichkeiten eines großen, transfer-gelernten Teacher-Modells auf kompakte Student-Architekturen die konventionellen Grenzen des "from scratch"-Trainings signifikant verschiebt.

Mit dem Modell S6_XL wurde ein State-of-the-Art-Kompromiss entwickelt, der 86.81 % Genauigkeit bei lediglich 1.84 Millionen Parametern erzielt. Damit übertrifft es die etablierte Baseline aus Station 1 deutlich und erreicht ein Klassifikationsniveau, das sehr nah an

überparametrisierte Transfer-Learning-Architekturen heranreicht, während Inferenzzeit und Speicherbedarf minimiert bleiben. Diese methodische Erkenntnis ist insbesondere für den operativen Einsatz in der modernen Astrophysik, in der gewaltige Datenmengen hochauflösender Himmelsdurchmusterungen in Echtzeit prozessiert werden müssen, von zentraler Bedeutung.

References

- [1] Tuan Le et al. Enhanced comparative analysis of pretrained and custom deep convolutional neural networks for galaxy morphology classification. *MDPI Algorithms*, 17(3):100–115, 2024. [3](#)
- [2] Henry W. Leung and Jo Bovy. astronnn: Deep learning for astronomers with tensorflow. <https://astronnn.readthedocs.io/en/latest/galaxy10.html>, 2019. Accessed: 2026-05-17. [3](#)
- [3] Alexander Nungesser. Deep learning project repository. <https://github.com/AlexanderNungesser/deep-learning>, 2026. Accessed: 2026-05-18. [2](#)
- [4] Alexander Nungesser. Klassifikation von galaxien im modul deep learning - meilenstein 1. Projektbericht, Hochschule Bielefeld (HSBI), Campus Minden, 2026. [1](#), [2](#), [3](#)
- [5] Alexander Nungesser. Transfer learning zur klassifikation von galaxien (deep learning - station 2). Projektpräsentation, Hochschule Bielefeld (HSBI), Campus Minden, 2026. [1](#), [2](#), [3](#)
- [6] Y. You. Evaluation of galaxy morphology classification with machine learning and deep learning. In *Proceedings of the International Conference on Information Technology and Applications*, pages 245–252. Atlantis Press, 2024. [3](#)

A. Zusätzliche Abbildungen und Plots




Figure 2. Trainings- und Validierungsverläufe (Accuracy) der sieben evaluierten Student-Modelle (S1_Nano bis S7_Max). Es zeigt sich, dass tiefere Architekturen (wie S6_XL) nicht nur eine höhere finale Genauigkeit erreichen, sondern auch eine deutlich stabilere und schnellere Konvergenz aufweisen.




Figure 3. Relativer Genauigkeitsgewinn durch Knowledge Distillation. Der Plot visualisiert die Differenz (Gain) in der Klassifikationsgenauigkeit zwischen Modellen, die mittels Knowledge Distillation trainiert wurden, und identischen Netzwerken, die *from scratch* (auf Hard Labels) trainiert wurden.




Figure 4. Gegenüberstellung von Parameterkomplexität und Testgenauigkeit über alle Meilensteine des Projekts. Zu sehen sind die Ergebnisse aus Station 1 (Custom Models), Station 2 (Transfer Learning, u. a. Zoobot) und Station 3 (Knowledge Distillation). Das Modell S6_XL positioniert sich als optimaler Kompromiss im linken oberen Quadranten (hohe Genauigkeit, geringe Parameter).




Figure 5. Repräsentative Beispiele der am häufigsten fehlklassifizierten morphologischen Kategorien. Die chaotische Struktur von Klasse 1 führt oft zu Verwechslungen mit kollidierenden Galaxien, während die Unterscheidung der Spiralwicklungsichte zwischen Klasse 7 und 8 selbst für menschliche Experten eine Herausforderung darstellt.